```
In [3]: import numpy as np
        import pandas as pd
        import scipy.stats
        import warnings
        warnings.filterwarnings("ignore")
        import os
        os.chdir("/Users/Lenovo/Desktop/EBAC")
        data = pd.read csv("Advertising.csv")
        Y = np.array(data["Sales"]).reshape(-1, 1)
X = np.array(data[["TV", "Radio", "Newspaper"]])
        # intercepto
        X = np.hstack([np.ones((X.shape[0], 1)), X])
        # Estimación de betas (MCO)
        XT_X = np.matmul(X.T, X)
        XT X inv = np.linalg.inv(XT X)
        XT_Y = np.matmul(X.T, Y)
        betas = np.matmul(XT X inv, XT Y)
        # Predicciones y residuos
        Y_pred = np.matmul(X, betas)
        Resid = Y - Y_pred
        RSS = np.matmul(Resid.T, Resid)
        TSS = np.matmul(Y.T, Y) - len(Y)*(Y.mean()**2)
        R2 = float(1 - RSS/TSS)
        n, k = X.shape
        s cuad = RSS / (n - k)
        s = float(np.sqrt(s_cuad))
        print("Coeficientes beta:")
        print(betas)
        print("R2:", R2)
        # Intervalo de confianza 90%
        # para TV=100, Radio=50, Newspaper=70
        f = np.array([[1, 100, 50, 70]])
        Pron puntual = float(np.matmul(f, betas))
        gl = n - k
        Confianza = 0.90
        q = (1 - Confianza) / 2
        t_critico = abs(scipy.stats.t.ppf(q, df=gl))
        Margen\_error = t\_critico * (s * (float(np.matmul(np.matmul(f, XT X inv), f.T))**0.5))
        Lim inferior = Pron puntual - Margen error
        Lim superior = Pron_puntual + Margen_error
        print("Predicción puntual:", Pron_puntual)
        print("Intervalo de confianza 90%: (", Lim_inferior, ",", Lim_superior, ")")
        # Validación de supuestos
        # Normalidad de residuos (Jarque-Bera)
        skew = float(scipy.stats.skew(Resid, bias=True))
        kurtosis = float(scipy.stats.kurtosis(Resid, fisher=False))
        Jarque_bera = (n/6) * (skew**2 + (kurtosis-3)**2 / 4)
        print("Asimetría:", skew)
        print("Curtosis:", kurtosis)
        print("Estadístico Jarque-Bera:", Jarque bera)
        # Autocorrelación (Durbin-Watson)
        from statsmodels.formula.api import ols
        from statsmodels.stats.stattools import durbin watson
        model = ols("Y ~ TV + Radio + Newspaper", data=df).fit()
        dw = durbin_watson(model.resid)
        print("Durbin-Watson:", dw)
        # Heterocedasticidad (Prueba de White)
        from statsmodels.stats.diagnostic import het white
        white test = het white(model.resid, model.model.exog)
        print("Estadístico White:", white_test[0])
```

```
print("Valor p White:", white_test[1])

Coeficientes beta:
[[4.62512408e+00]
[5.44457803e-02]
[1.07001228e-01]
[3.35657922e-04]]
R²: 0.9025912899684556
Predicción puntual: 15.44325957906403
Intervalo de confianza 90%: (14.954628615233734 , 15.931890542894326 )
Asimetría: -0.4310967996702898
Curtosis: 4.604756333677674
Estadístico Jarque-Bera: 27.65517244352062
Durbin-Watson: 2.250551836079356
Estadístico White: 19.95314047160226
Valor p White: 0.018203803931681445
```

Jarque - Bera: Dado que el estadístico de Jarque-Bera es mayor al valor crítico, rechazamos la hipótesis nula y concluimos que los residuales no siguen una distribución normal.

Durbin-Watson: Dado que DW = 2.25, que es mayor que 2, se evidencia una ligera autocorrelación negativa entre los residuales.

Estadistico de White: Dado que el valor p de la prueba de White es menor que 0.05, rechazamos la hipótesis nula y concluimos que existe heterocedasticidad en los residuales (varianzas desiguales).

Multicolinealidad: Todas las variables independientes tienen VIF cercanos a 1, lo que indica que no existe multicolinealidad significativa en el modelo.

```
import statsmodels.api as sm

# intercepto
X_train_const = sm.add_constant(X_train)

# Ajuste del modelo
model = sm.OLS(y_train, X_train_const).fit()
print(model.summary())
```

OLS Regression Results

			=======================================
Dep. Variable:	Sales	R-squared:	0.899
Model:	0LS	Adj. R-squared:	0.897
Method:	Least Squares	F-statistic:	405.2
Date:	Tue, 09 Sep 2025	Prob (F-statistic):	1.36e-67
Time:	18:13:17	Log-Likelihood:	-272.35
No. Observations:	140	AIC:	552.7
Df Residuals:	136	BIC:	564.5
Df Model:	3		
Covariance Type:	nonrobust		

	· · ·					
	coef	std err	t	P> t	[0.025	0.975]
const TV Radio Newspaper	4.6614 0.0550 0.1025 -0.0015	0.368 0.002 0.010 0.007	12.650 32.747 9.801 -0.203	0.000 0.000 0.000 0.839	3.933 0.052 0.082 -0.016	5.390 0.058 0.123 0.013
Omnibus: Prob(Omnibus Skew: Kurtosis:	;): 	- 0	.000 Jarq	in-Watson: ue-Bera (JB (JB): . No.):	2.041 25.876 2.41e-06 432.

Notes

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
In [13]: X_train_sig = X_train[["TV", "Radio"]]
    X_train_sig = sm.add_constant(X_train_sig)

model_sig = sm.OLS(y_train, X_train_sig).fit()
print(model_sig.summary())
```

OLS Regression Results

```
______
Dep. Variable:

Model:

Model:

Method:

Date:

Sales

R-squared:

Adj. R-squared:

F-statistic:

Prob (F-statistic):
                                                                      0.898
                                                                     612.0
                                                               612.0
4.95e-69
                  Tue, 09 Sep 2025 Prob (F-statistic):
18:13:32 Log-Likelihood:
140 AIC:
                                                                   -272.37
Time:
No. Observations:
                                                                      550.7
                                137 BIC:
Df Residuals:
                                                                      559.6
Df Model:
                                 2
Covariance Type: nonrobust
                             err t P>|t| [0.025 0.975]
              coef std err
-----

    const
    4.6390
    0.350
    13.240
    0.000
    3.946
    5.332

    TV
    0.0550
    0.002
    32.903
    0.000
    0.052
    0.058

    Radio
    0.1016
    0.010
    10.677
    0.000
    0.083
    0.120

_____
                         14.841 Durbin-Watson:
0.001 Jarque-Bera (JB):
-0.512 Prob(JB):
Omnibus:
                                                                    24.663
Prob(Omnibus):
                                                                 4.41e-06
Skew:
                              4.783 Cond. No.
                                                                      407.
Kurtosis:
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
In [15]: from sklearn.metrics import r2_score

# Preparar X_test con solo las variables significativas
X_test_sig = sm.add_constant(X_test[["TV", "Radio"]])

# Predicciones
y_pred = model_sig.predict(X_test_sig)

# R² en prueba
r2_test = r2_score(y_test, y_pred)
print("R² en conjunto de prueba:", r2_test)
```

R² en conjunto de prueba: 0.9073562242286408

```
In [19]: import scipy.stats
         from statsmodels.formula.api import ols
         from statsmodels.stats.stattools import durbin_watson
         from statsmodels.stats.diagnostic import het white
         import pandas as pd
         data = pd.read_csv("Advertising.csv")
         df = pd.DataFrame({
             "Y": data["Sales"],
             "TV": data["TV"],
             "Radio": data["Radio"],
             "Newspaper": data["Newspaper"]
         })
         # Ajustar modelo de regresión
         model = ols("Y ~ TV + Radio + Newspaper", data=df).fit()
         resid = model.resid
         # Sesao
         skew lib = float(scipy.stats.skew(resid, bias=True))
         kurtosis_lib = float(scipy.stats.kurtosis(resid, fisher=False))
         # Durbin-Watson
         dw lib = durbin watson(resid)
         # Heterocedasticidad (White)
         white_test = het_white(resid, model.model.exog)
         white stat lib = white test[0]
         white_pvalue_lib = white_test[1]
         print("Sesgo (skew) librería:", skew_lib)
         print("Curtosis librería:", kurtosis lib)
         print("Durbin-Watson librería:", dw_lib)
         print("White test estadístico:", white stat lib)
         print("White test valor p:", white_pvalue_lib)
```

Sesgo (skew) librería: -0.4310967996702909 Curtosis librería: 4.604756333677675 Durbin-Watson librería: 2.250551836079356 White test estadístico: 19.95314047160226 White test valor p: 0.018203803931681445

Conclusion

Despues de hacer la comparativa de los calculos de matrices manuales VS las librerias, podemos concluir que los calculos manuales fueron exitosos, ya que llegamos a los mismos valores.

```
In [22]: from statsmodels.stats.outliers_influence import variance_inflation_factor
         import pandas as pd
         X = data[["TV", "Radio", "Newspaper"]]
         X = sm.add_constant(X)
         vif_data = pd.DataFrame()
         vif_data["Variable"] = X.columns
         vif_data["VIF"] = [variance_inflation_factor(X.values, i) for i in range(X.shape[1])]
         print(vif_data)
            Variable
                            VIF
              const 6.848900
TV 1.004611
Radio 1.144952
        0
        1
        2
        3 Newspaper 1.145187
 In [ ]:
```

Loading [MathJax]/jax/output/CommonHTML/fonts/TeX/fontdata.js